LSTM 모델을 활용한 품목별 수요예측 모델링

제 4 회 유통데이터 활용 경진대회 (수요예측 부문) 분석보고서 요약서

팀명 : 유통헌터스

Ⅰ. 서론

1.1 분석 배경 및 목표

최근 유통산업은 경기 변동성 확대와 기후 변화로 인해 제품 수요의 불확실성이 커지고 있다. 이에 따라 **재고 과잉 및 품절 리스크를 최소화하고, 품목별 수요예측 모델의 필요성이 강조되고 있다.**

본 공모의 목표는 신선식품,생수·음료·건강,봉지라면,탄산음료의 월별 판매수량(EA)을 예측하고, 기온·강수량 등 기상요인, 물가지수(CPI), 소비자심리지수(CCSI)의 경제지표, 명절,COVID19 의 사회·정책 외생 변수가 수요에 미치는 영향을 통계적으로 규명하는 것이다.

1.2 분석 프로세스

단계	세부 내용	사용 기법 및 환경
데이터 수집 (Data Collection)	내부 매출/매입 데이터 및 기상, 경제, 사회·정책 변수 데이터	데이터 처리: pandas, numpy 분석 환경: Google Colab, Jupyter, Excel
데이터 전처리 (Preprocessing)	데이터 정제(Data cleaning) 결측치 처리, 이상치 보정, 정규화(MinMaxScaler), 인코딩(Binary)	전처리 및 통계: scikit-learn, statsmodels

변수 선택 (Feature Selection)	상관분석 (Pearson + p-value), t-test (이항 변수 검정) 의사결정나무 (Decision Tree Regressor)로 변수 중요도 도출	전처리 및 통계: s cikit-learn, statsmodels
모델 학습 (Modeling & Training)	LSTM 기반 시계열 학습, Validation Set 검증	모델링: tensorflow(keras), xgboost
예측 및 평가 (Prediction & Evaluation)	RMSE, MAE, MAPE 비교를 통한 모델 성능 평가 및 최적 모델 선정	matplotlib, seaborn
인사이트 도출 (Insight & Forecasting)	품목별 수요 패턴 분석 (기후형 vs 경기형) 및 발주 전략 제안	시각화: matplotlib, seaborn

[그림 1] 유통 수요예측 분석 전체 프로세스

Ⅱ. 본론

2.1 데이터 수집(Data Collection)

유통 공모전에서 제공한 A·B 물류센터의 매입 및 매출 데이터를 활용하였다.

분석 대상은 신선식품,생수·음료·건강,봉지라면,탄산음료 4 개 품목이며, 2021 년부터 2024 년까지의 월별 EA(판매수량) 데이터를 기반으로 하였다.

구분	데이터	기간	주요 컬럼	비고
A 물류센터	매입 / 매출	2021~2024	일자, EA, 중분류	생수·신선식품
B 물류센터	매입 / 매출	2021~2024	일자, EA, 소분류	봉지라면·탄산음료
외부데이터	기상, 경제, 사회·정책 변수	2021~2024	폭염일수, 한파일수, 평균기온, 평균일교차, 강수량, CPI, CCSI, 명절, COVID-19	명절여부 해당 월에 명절이 존재하는지 여부 COVID-19 여부 기준 : 거리두기 해제 일자 (2022 년 04 월)

※ 봉지라면의 생활물가지수(CPI)는 품목 특성에 따라 '라면물가지수'로 구분하여 사용함.

내부 데이터(A·B 물류센터 매입·매출)와 외부 변수(기상, 경제, 사회·정책)를 통합하여 분석 데이터를 구성하였다.

전처리 단계에서는 결측치 대체, 이상치 보정, 정규화(MinMaxScaler), 이진 변수화(Binary Encoding)을 수행하여 변수 간 단위 차이를 최소화하였다.

이후 의사결정나무(회귀)를 적용해 변수 중요도(Feature Importance)를 산출하고, 상관분석 및 t-test 결과 유의하며 중요도가 5% 이상인 변수를 핵심 변수로 선정하였다.

2.2 데이터 전처리 (Data Preprocessing)

2.2.1 데이터 정제 및 결합 (A,B 공통)

- 연도별로 분리되어 제공된 데이터의 컬럼명을 통일하여 시계열 데이터로 결합하였다.
- 매입 데이터는 '입고', 매출 데이터는 '매출' 유형만 필터링하였다.
- 매입 데이터의 **'매입일자', 'EA',** 매출 데이터의 **'판매일', '판매수량'** 을 제외한 **비분석용 컬럼(작업유형, 매출처코드, 공급처명, 우편번호, 비고 등)** 을 제거하였다.

2.2.2 데이터 정제 과정 (A 물류센터)

- 매입과 매출 데이터에서 중분류가 '신선식품', '생수·음료·건강'인 상품만을 분석 대상으로 설정하였다.

작업유형	일자	상품명	입수	EA	중분류
입고	2023-05-24	농심]새우탕큰사발<6>	6	300	생수,음료,건강
입고	2023-05-26	농심]새우탕큰사발<6>	6	120	생수,음료,건강
입고	2023-05-30	농심]새우탕큰사발<6>	6	180	생수,음료,건강
입고	2023-05-31	농심]새우탕큰사발<6>	6	180	생수,음료,건강
입고	2023-06-05	농심]새우탕큰사발<6>	6	60	생수,음료,건강
입고	2024-03-07	농심]새우탕큰사발<6>	6	240	생수,음료,건강
입고	2024-03-08	농심]새우탕큰사발<6>	6	300	생수,음료,건강
입고	2024-05-21	농심]새우탕큰사발<6>	6	300	생수,음료,건강
입고	2024-06-03	농심]새우탕큰사발<6>	6	120	생수,음료,건강

- **생수·음료·건강 데이터에서 '농심]새우탕큰사발<6>' 비관련 품목을 제거하였다.**

5 #매입

지역	count
경상북도	8971
대구광역시	5627
서울특별시	4200
경상남도	855
부산광역시	259
충청남도	29
경기도	13
전라북도	12
울산광역시	5

dtype: int64

11 #매출

지역	count
경상북도	163624
전라남도	728
부산광역시	543
경상남도	348
경기도	331
충청남도	131
울산광역시	116
서울특별시	86

dtype: int64

- 지역별 데이터 분석 결과, 경상북도 데이터 비중이 높으나 모델의 **일반화 성능 확보 및 전국 단위 수요 예측 정확도 향상**을 위해 **모든 지역 데이터를 포함하여 학습에 반영하였다.**

```
4 #매입
```

요일이름	count
Tuesday	4554
Wednesday	4335
Thursday	4161
Friday	3707
Monday	3204
Saturday	10

dtype: int64

```
4 #매출
```

요일이름	count
Friday	43402
Monday	35839
Thursday	31456
Tuesday	28896
Wednesday	25991
Saturday	323

dtype: int64

- 요일별 데이터 분석 결과, 토요일을 제외한 나머지 요일간의 데이터 불균형이 경미하여, 모든 요일 데이터를 유지하였다.

2.2.3 데이터 정제 과정 (B 물류센터)

- 매입과 매출 데이터에서 소분류가 '탄산음료', '봉지라면'인 상품만을 분석 대상으로 설정하였다.

작업유형	일자	상품명	옵션 코드	입수	수량	EA	소분류
반출	2021-04-08	(농심)포테토칩_김치사발면맛60g	EA	1	-32	-32	봉지라면
반출	2021-05-13	(농심)포테토칩_김치사발면맛60g	EA	1	-16	-16	봉지라면
반출	2021-07-05	(농심)포테토칩_김치사발면맛60g	EA	1	-13	-13	봉지라면

-봉지라면 데이터에서 '(농심)포테토칩_김치사발면맛 60g' 비관련 품목을 제거하였다.

매입

매출처 우편번호	count
경상남도	75083
대구광역시	4655
제주특별자치도	1600
부산광역시	591
광주광역시	56
전북특별자치도	30
경상북도	28
대전광역시	12
경기도	10
충청북도	9

dtype: int64

매출

```
지역
경상남도        71264
대구광역시        4404
제주특별자치도    1460
부산광역시        585
광주광역시         56
전북특별자치도     28
경상북도          19
대전광역시         11
경기도            10
충청북도           9
서울특별시         1
Name: count, dtype: int64
```

- 지역별 데이터 분석 결과, 경상남도 데이터 비중이 높으나 모델의 **일반화 성능 확보 및 전국 단위 수요 예측 정확도 향상**을 위해 **모든 지역 데이터를 포함하여 학습에 반영하였다.**

```
요일
Friday       856
Monday       848
Tuesday      831
Thursday     770
Wednesday    710
Saturday     319
Name: count, dtype: int64
```

- 요일별 데이터 분석 결과, 일요일을 제외한 나머지 요일간의 데이터 불균형이 경미하여, 모든 요일 데이터를 유지하였다.

2.2.4 결측치 탐색 (EDA)

결측치는 A 물류센터 데이터에서만 확인되었으며, 본 분석의 최종 예측 단위가 월별 예측이므로 결측 여부를 월 단위로 재확인하였다.

결측 구간은 두 품목(신선식품, 생수·음료·건강) 모두 2023.03 ~ 2023.12 및 2024.07 ~ 2024.12 로 동일하였으며, 전체 데이터 대비 결측률은 약 8~10% 수준으로 나타났다.

2.2.5 결측치 처리방식 및 이유

구간	적용 품목	처리 방식	적용 이유
2023.03~06	신선식품 / 생수·음료·건강	전년도와 후년도의 평균값 보간	계절성과 추세를 동시에 반영하기 위함
2023.07~12	신선식품 / 생수·음료·건강	전년 동월값 대체	동일 월 내 수요 패턴 보존
2024.07~12	신선식품 / 생수·음료·건강	결측치 제거	2025.01~03 예측에 직접 영향 → 왜곡 방지

2.2.6 결측치 시각화 결과

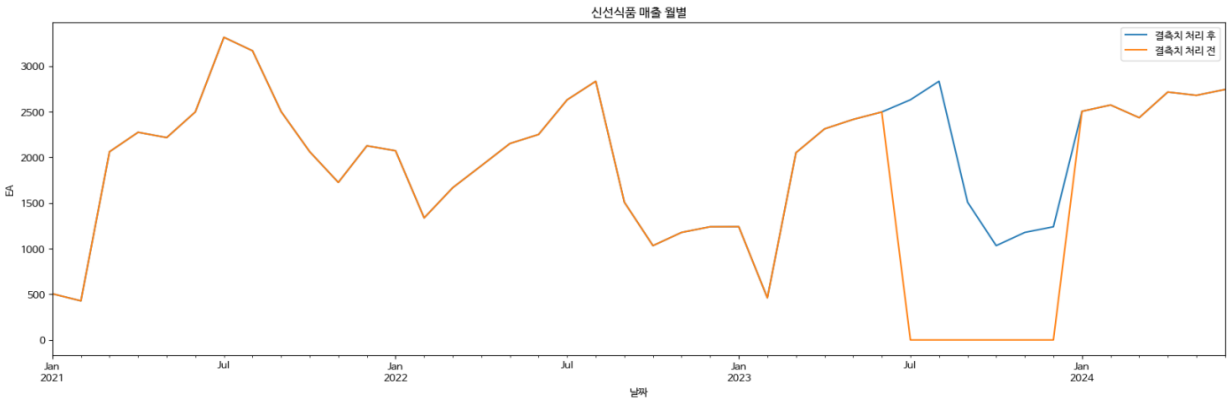

[그림 1] 신선식품 매출 월별 결측치 처리 전/후 비교

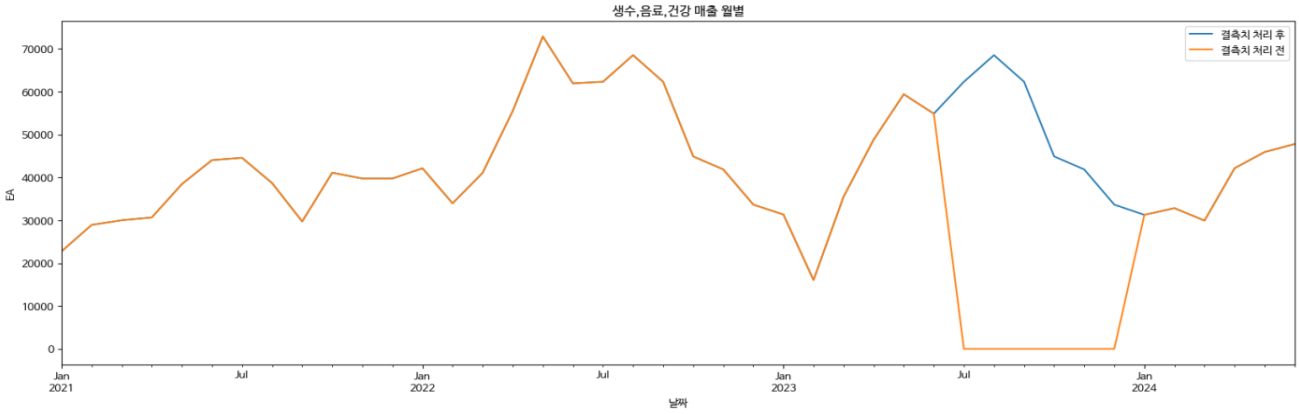

[그림 2] 생수·음료·건강 매출 월별 결측치 처리 전/후 비교

2.2.7 이상치 탐색(EDA)

- 이상치는 Box Plot 을 통해 탐지하였으며, IQR(Interquartile Range) 방식을 적용하여 하한치(Q1 – 1.5 × IQR)와 상한치(Q3 + 1.5 × IQR)를 벗어나는 값을 이상치로 판정하였다.

판정된 이상치는 Winsorization(윈저화) 기법을 적용하여 처리하였다. 이는 이상값을 제거하지 않고, 상·하한 임계값으로 대체하여 데이터의 왜곡을 최소화하기 위함이다.

2.2.8 A 물류센터 이상치 보정

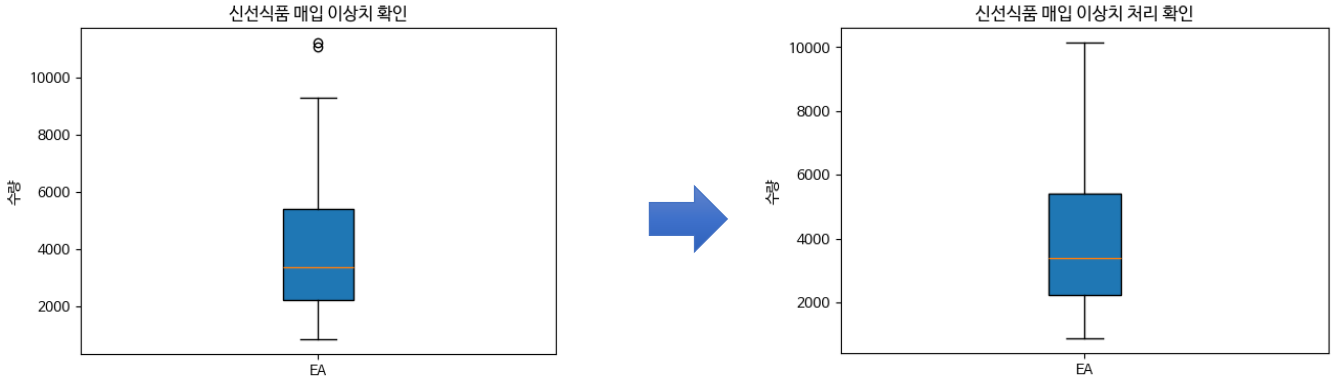

- 신선식품 매입 데이터 이상치 확인 결과, 상한치(Q3 + 1.5 × IQ)를 초과하는 값으로 확인되어, 해당 구간의 이상치를 상한치 값으로 대체한 후 분포가 안정화되었음을 확인하였다.

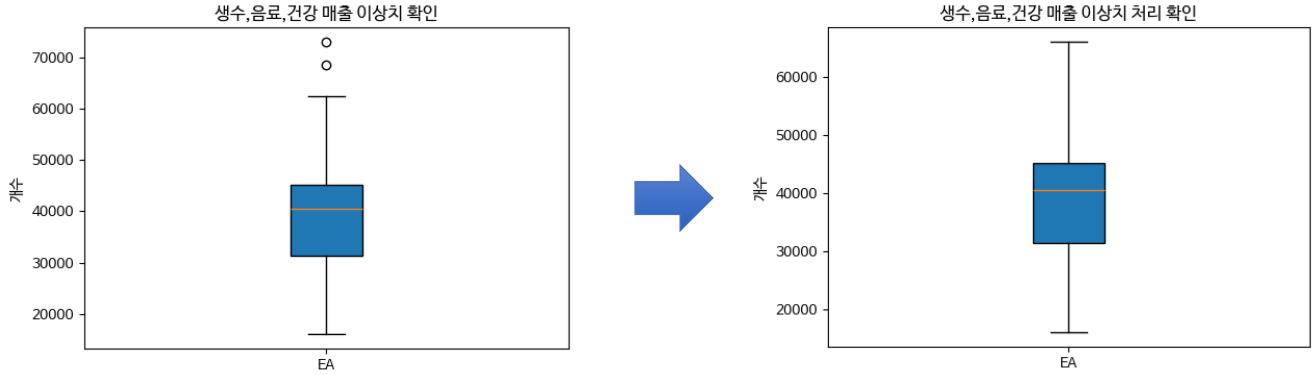

- 생수·음료·건강 매출 데이터 이상치 확인 결과, 상한치(Q3 + 1.5 × IQ)를 초과하는 값으로 확인되어, 해당 구간의 이상치를 상한치 값으로 대체한 후 분포가 안정화되었음을 확인하였다.

2.2.9 B 물류센터 이상치 보정

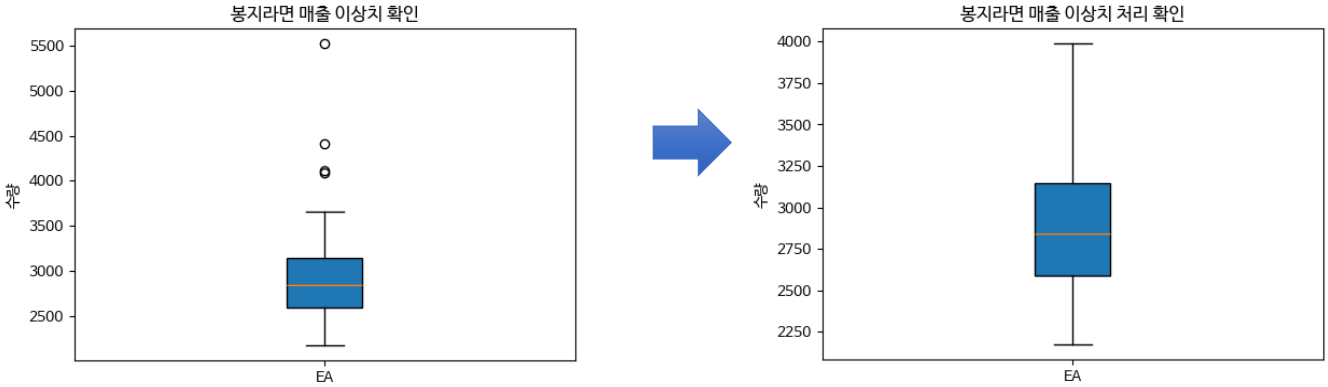

- 봉지라면 매출 데이터 이상치 확인 결과, 상한치(Q3 + 1.5 × IQ)를 초과하는 값으로 확인되어, 해당 구간의 이상치를 상한치 값으로 대체한 후 분포가 안정화되었음을 확인하였다.

2.3.1 데이터 스케일링 및 인코딩 (Data Scaling & Encoding)

구분	적용 변수	처리 방식
수치형 변수	폭염일수, 한파일수, 평균기온, 평균일교차,강수량, 소비자심리지수, 생활물가지수	MinMaxScaler
범주형 변수	COVID-19, 명절, 지역코드	Binary Encoding

2.3.2 파생변수 생성 (Feature Engineering)

내부 판매데이터에 기상,경제,사회·정책적 요인을 반영한 파생변수를 생성하여,

품목별 수요 변화의 외부적 영향을 통합적으로 고려하였으며, 이후 생성된 변수 간의 상관관계를 분석하여 예측모델 학습에 활용할 주요 변수를 선별하였다.

	일자	EA	평균 폭염일수	평균 한파일수	평균기온(℃)	평균일교차	강수량	소비자심리지수	생활물가지수	COVID_19	명절
0	2021-01-01	22760.0	0.0	5.5	-1.1	10.8	19.9	95.2	100.17	0	0
1	2021-02-01	28932.0	0.0	0.4	3.4	11.6	20.1	97.4	100.17	0	1
2	2021-03-01	30019.0	0.0	0.0	8.7	11.7	110.7	100.6	100.17	0	0
3	2021-04-01	30679.0	0.0	0.0	13.2	12.0	76.3	102.5	100.17	0	0

↓ 기상요인 ↓ 경제지표 ↓ 사회/정책

[그림 1]생수·음료·건강, 탄산음료, 봉지라면 매입, 매출 데이터 파생변수

	일자	EA	평균 폭염일수	평균 한파일수	평균기온(℃)	평균일교차	강수량	소비자심리지수	COVID_19	명절
0	2021-01-01	859.00	0.0	5.5	-1.1	10.8	19.9	95.2	0	0
1	2021-02-01	1191.00	0.0	0.4	3.4	11.6	20.1	97.4	0	1
2	2021-03-01	7447.00	0.0	0.0	8.7	11.7	110.7	100.6	0	0
3	2021-04-01	2314.00	0.0	0.0	13.2	12.0	76.3	102.5	0	0

↓ 기상요인 ↓ 경제지표 ↓ 사회/정책

[그림 2]신선식품 매입, 매출 데이터 파생변수

(KOSIS 서비스 중단으로 신선식품만 CPI 항목 제외)

3.1 변수 선택(Feature Selection)

상관분석(Pearson Correlation)과 t-test 를 통해 통계적으로 유의한 변수를 선별하였고, 의사결정나무(Decision Tree Regressor)를 활용해 변수의 중요도(Feature Importance)를 산출하고, 이를 1(100%)로 정규화하여 비교하였다.

3.1.1 상관분석(Pearson Correlation) 결과

구분	매입	매출	해석	**변수 중요도**
신선식품	평균기온 r=0.588, 강수량 r=0.481 (+), 한파일수 r=-0.375 (-)	평균기온 r=0.628, 강수량 r=0.564 (+), 폭염일수 r=0.525 (+), 한파일수 r=-0.423 (-)	기온·강수량 높을수록(+) 수요 증가(+)	**핵심변수: 평균기온** **보조요인: 강수량,** **폭염일수**
생수·음료·건강	평균기온 r=0.767, 폭염일수 r=0.404 (+), 한파일수 r=-0.386 (-)	평균기온 r=0.720, 강수량 r=0.554 (+), 폭염일수 r=0.443 (+), 한파일수 r=-0.396 (-)	기온상승시(+) 수요 증가(+), 한파일수는 역상관(-)	**핵심변수: 평균기온** **보조요인: 폭염일수**
탄산음료	평균기온 r=0.487 (+)	평균기온 r=0.663 (+), 폭염일수 r=0.459 (+), 한파일수 r=-0.396 (-), 강수량 r=0.371 (+)	여름철 고온(+) 영향 강함(+)	**핵심변수: 평균기온** **부가요인: 폭염일수**
봉지라면	CPI r=-0.395 (-)	(유의변수 없음)	경기둔화 시(-) 매입량 증가(+)	**핵심변수: CPI**

3.1.2 T-test (이항변수 유의성 검증) 결과

구분	매입	매출	해석
생수·음료·건강	명절 p=0.1281 COVID p=0.8767	명절 p= 0.6473 COVID p=0.0011 (채택)	명절 전후 판촉·구매 집중 영향
신선식품	명절 p= 0.0054 COVID p= 0.9738 (채택)	명절 p= 0.2747 COVID p= 0.009833	명절 수요 반영 (가정식·식자재 소비 증가)
탄산음료	명절 p= 0.2500 COVID p= 0.6329	명절 p= 0.3000 COVID p= 0.7623	주말 소비 패턴 반영
봉지라면	명절 p= 0.4502 COVID p= 0.0054 (채택)	명절 p= 0.1382 COVID p=0.1437	주중 대비 주말 수요 증가

3.1.3 의사결정나무 (Decicion Tree Regressor) 기반 변수 중요도 산출

구분	주요 변수(상위 3 개)	중요도(%)
탄산음료_매입	평균기온(℃): 35.5QPI: 24.2QSI: 20.1	약 80
탄산음료_매출	평균 강수량: 48.0QSI: 20.0QPI: 17.4	약 85
봉지라면_매입	QPI: 36.1 강수량: 34.2 평균기온: 28.0	약 98
봉지라면_매출	QPI: 57.0QSI: 30.0 강수량: 6.6	약 93
생수_매입	평균강수량: 69.7QSI: 17.8QPI: 10.7	약 98
생수_매출	평균강수량: 46.1QSI: 13.4QPI: 10.7	약 70
신선식품_매입	QPI: 42.4QSI: 19.0 평균기온: 8.5	약 70
신선식품_매출	평균강수량: 49.2QPI: 15.5QSI: 13.4	약 78

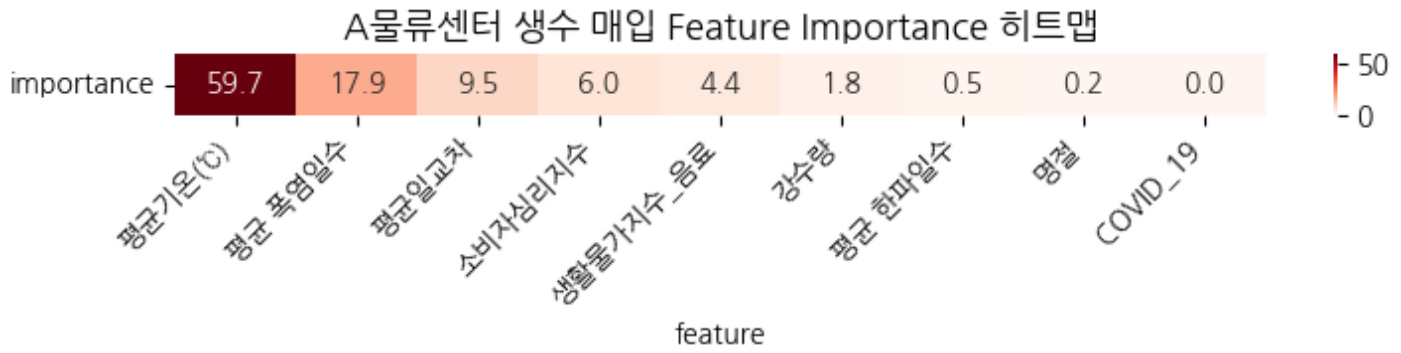
A물류센터 생수 매입 Feature Importance 히트맵
importance
59.7
17.9
9.5
6.0
4.4
1.8
0.5
0.2
0.0
50
0
평균기온(℃)
평균 폭염일수
평균일교차
소비자심리지수
생활물가지수_음료
강수량
평균 한파일수
명절
COVID_19
feature

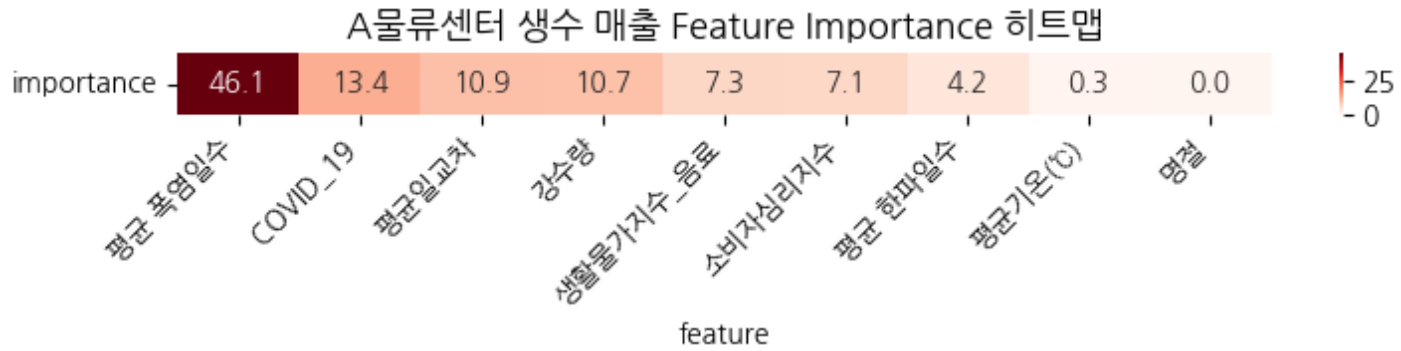
A물류센터 생수 매출 Feature Importance 히트맵
importance
46.1
13.4
10.9
10.7
7.3
7.1
4.2
0.3
0.0
25
0
평균 폭염일수
COVID_19
평균일교차
강수량
생활물가지수_음료
소비자심리지수
평균 한파일수
평균기온(℃)
명절
feature

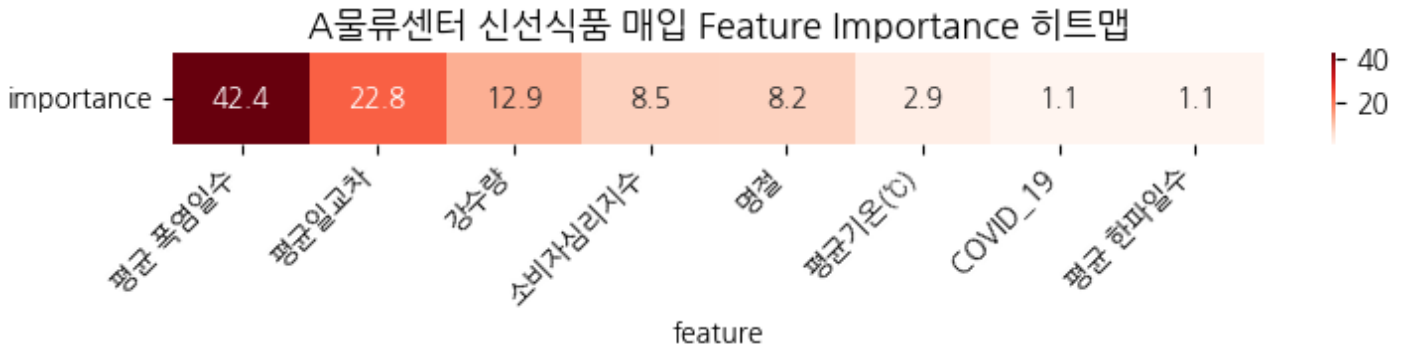
A물류센터 신선식품 매입 Feature Importance 히트맵
importance
42.4
22.8
12.9
8.5
8.2
2.9
1.1
1.1
40
20
평균 폭염일수
평균일교차
강수량
소비자심리지수
명절
평균기온(℃)
COVID_19
평균 한파일수
feature

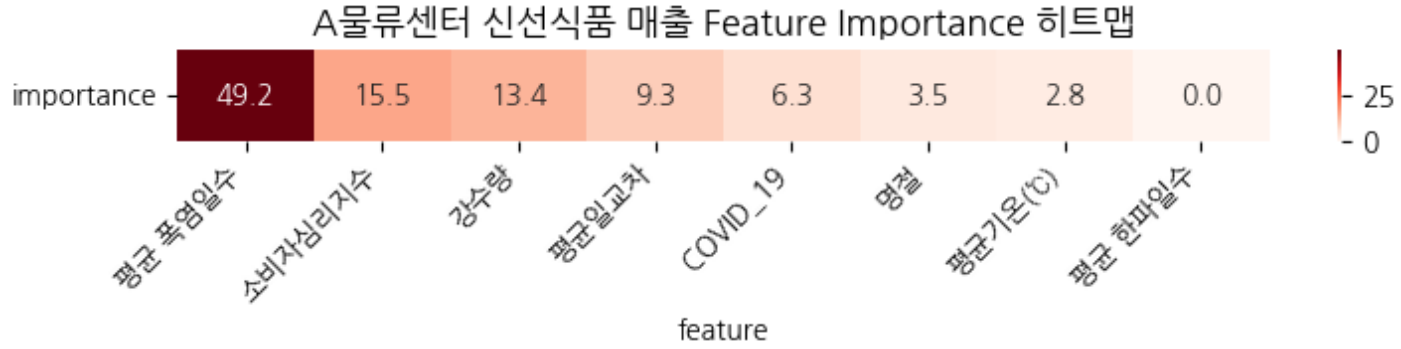
A물류센터 신선식품 매출 Feature Importance 히트맵
importance
49.2
15.5
13.4
9.3
6.3
3.5
2.8
0.0
25
0
평균 폭염일수
소비자심리지수
강수량
평균일교차
COVID_19
명절
평균기온(℃)
평균 한파일수
feature

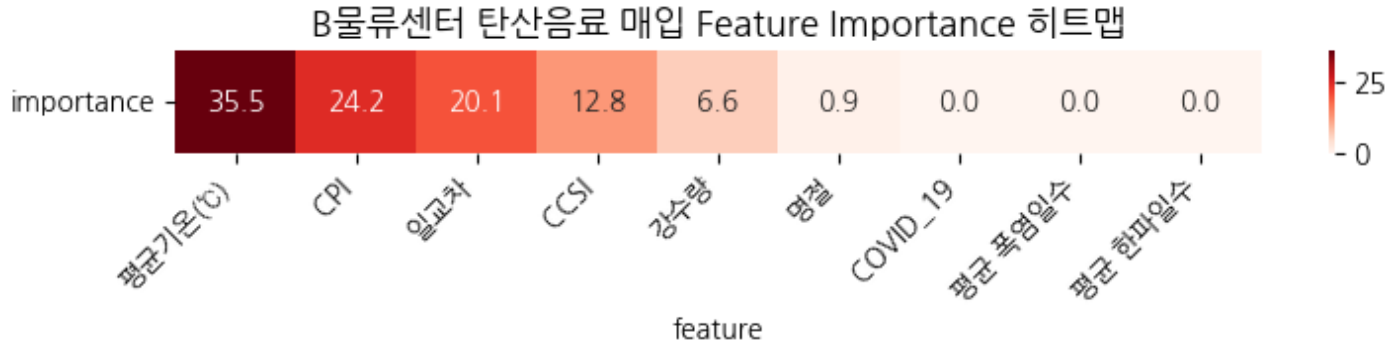
B물류센터 탄산음료 매입 Feature Importance 히트맵
importance
35.5
24.2
20.1
12.8
6.6
0.9
0.0
0.0
0.0
평균기온(℃)
CPI
일교차
CCSI
강수량
명절
COVID_19
평균 폭염일수
평균 한파일수
feature
25
0

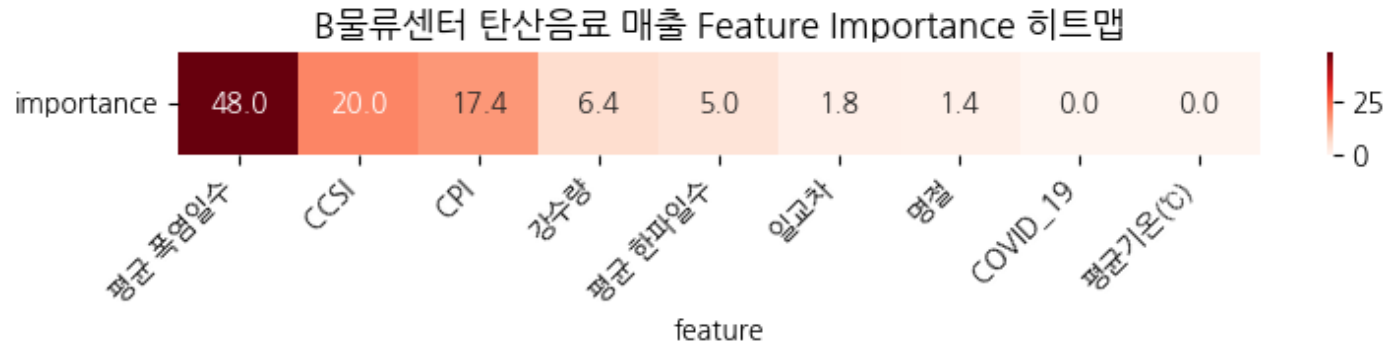
B물류센터 탄산음료 매출 Feature Importance 히트맵
importance
48.0
20.0
17.4
6.4
5.0
1.8
1.4
0.0
0.0
평균 폭염일수
CCSI
CPI
강수량
평균 한파일수
일교차
명절
COVID_19
평균기온(℃)
feature
25
0

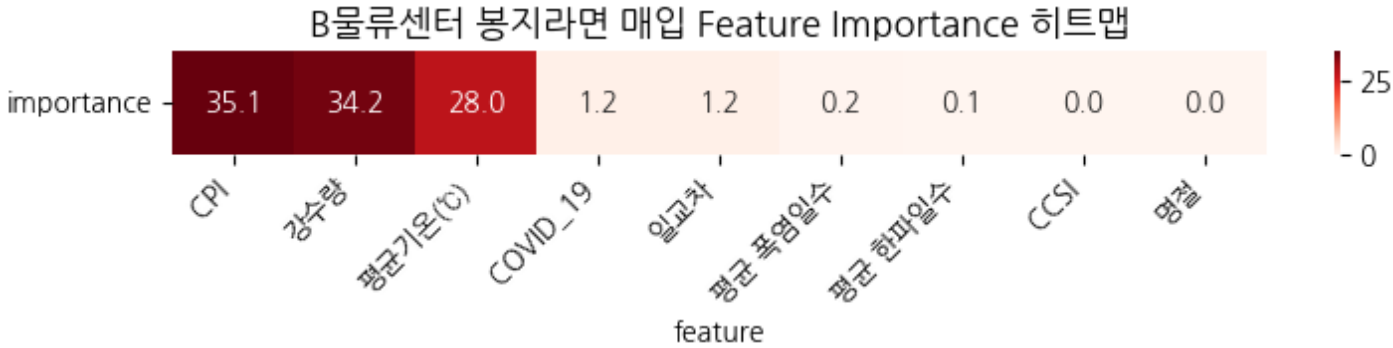
B물류센터 봉지라면 매입 Feature Importance 히트맵
importance
35.1
34.2
28.0
1.2
1.2
0.2
0.1
0.0
0.0
CPI
강수량
평균기온(℃)
COVID_19
일교차
평균 폭염일수
평균 한파일수
CCSI
명절
feature
25
0

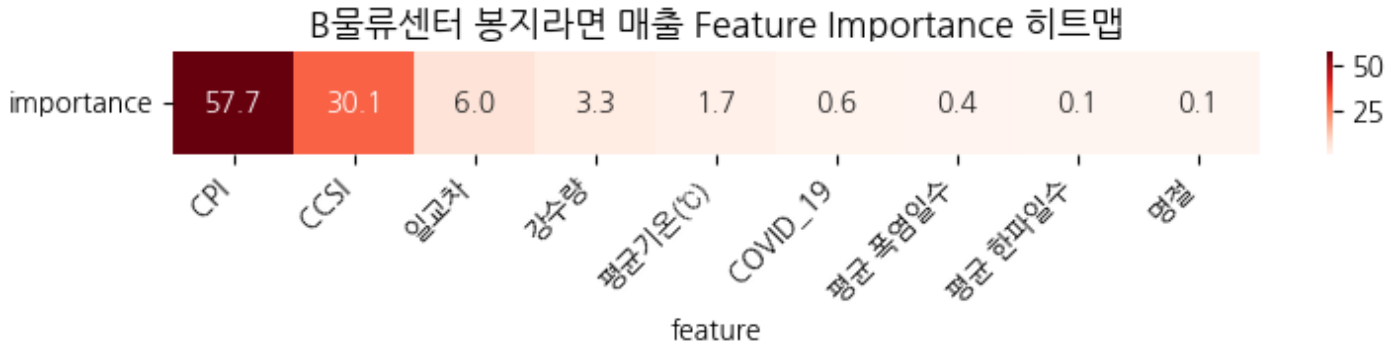
B물류센터 봉지라면 매출 Feature Importance 히트맵
importance
57.7
30.1
6.0
3.3
1.7
0.6
0.4
0.1
0.1
CPI
CCSI
일교차
강수량
평균기온(℃)
COVID_19
평균 폭염일수
평균 한파일수
명절
feature
50
25

```
B물류센터_탄산음료_매입
----------------------------------
feature : 평균기온(℃) -> importance : 35.5
feature : CPI -> importance : 24.2
feature : 일교차 -> importance : 20.1
feature : CCSI -> importance : 12.8
feature : 강수량 -> importance : 6.6000000000000005
feature : 명절 -> importance : 0.8999999999999999
feature : COVID_19 -> importance : 0.0
feature : 평균 폭염일수 -> importance : 0.0
feature : 평균 한파일수 -> importance : 0.0
```

```
B물류센터_탄산음료_매출
----------------------------------
feature : 평균 폭염일수 -> importance : 48.0
feature : CCSI -> importance : 20.0
feature : CPI -> importance : 17.4
feature : 강수량 -> importance : 6.4
feature : 평균 한파일수 -> importance : 5.0
feature : 일교차 -> importance : 1.7999999999999998
feature : 명절 -> importance : 1.4000000000000001
feature : COVID_19 -> importance : 0.0
feature : 평균기온(℃) -> importance : 0.0
```

```
B물류센터_봉지라면_매입
----------------------------------
feature : CPI -> importance : 35.099999999999994
feature : 강수량 -> importance : 34.2
feature : 평균기온(℃) -> importance : 28.000000000000004
feature : COVID_19 -> importance : 1.2
feature : 일교차 -> importance : 1.2
feature : 평균 폭염일수 -> importance : 0.2
feature : 평균 한파일수 -> importance : 0.1
feature : CCSI -> importance : 0.0
feature : 명절 -> importance : 0.0
```

```
B물류센터_봉지라면_매출(이상치 처리 완)
----------------------------------
feature : CPI -> importance : 57.699999999999996
feature : CCSI -> importance : 30.099999999999998
feature : 일교차 -> importance : 6.0
feature : 강수량 -> importance : 3.3000000000000003
feature : 평균기온(℃) -> importance : 1.7000000000000002
feature : COVID_19 -> importance : 0.6
feature : 평균 폭염일수 -> importance : 0.4
feature : 평균 한파일수 -> importance : 0.1
feature : 명절 -> importance : 0.1
```

```
A물류센터_생수_매입
----------------------------------
feature : 평균기온(℃) -> importance : 59.699999999999996
feature : 평균 폭염일수 -> importance : 17.9
feature : 평균일교차 -> importance : 9.5
feature : 소비자심리지수 -> importance : 6.0
feature : 생활물가지수_음료 -> importance : 4.3999999999999995
feature : 강수량 -> importance : 1.7999999999999998
feature : 평균 한파일수 -> importance : 0.5
feature : 명절 -> importance : 0.2
feature : COVID_19 -> importance : 0.0
```

```
A물류센터_생수_매출
----------------------------------
feature : 평균 폭염일수 -> importance : 46.1
feature : COVID_19 -> importance : 13.4
feature : 평균일교차 -> importance : 10.9
feature : 강수량 -> importance : 10.7
feature : 생활물가지수_음료 -> importance : 7.3
feature : 소비자심리지수 -> importance : 7.1
feature : 평균 한파일수 -> importance : 4.2
feature : 평균기온(℃) -> importance : 0.3
feature : 명절 -> importance : 0.0
```

```
A물류센터_신선식품_매입
----------------------------------
feature : 평균 폭염일수 -> importance : 42.4
feature : 평균일교차 -> importance : 22.8
feature : 강수량 -> importance : 12.9
feature : 소비자심리지수 -> importance : 8.5
feature : 명절 -> importance : 8.200000000000001
feature : 평균기온(℃) -> importance : 2.9000000000000004
feature : COVID_19 -> importance : 1.0999999999999999
feature : 평균 한파일수 -> importance : 1.0999999999999999
```

```
A물류센터_신선식품_매출
----------------------------------
feature : 평균 폭염일수 -> importance : 49.2
feature : 소비자심리지수 -> importance : 15.5
feature : 강수량 -> importance : 13.4
feature : 평균일교차 -> importance : 9.3
feature : COVID_19 -> importance : 6.3
feature : 명절 -> importance : 3.5000000000000004
feature : 평균기온(℃) -> importance : 2.8000000000000003
feature : 평균 한파일수 -> importance : 0.0
```

[그림 1] 각 품목별 의사결정나무 기반 변수 중요도 분석 결과

3.1.4 변수 채택 결과 요약

품목	최종 채택 변수	비고
생수	평균기온, 폭염일수, 강수량, 일교차, CCSI	기상·심리지수 변수 중심
신선식품	폭염일수, 강수량, 일교차, CCSI, 명절	계절·심리·명절 변수 반영
탄산음료	폭염일수, CPI, CCSI, 한파일수, 강수량	온도·물가지수 영향 강함
봉지라면	CPI, CCSI, 일교차	경기 대체재 효과 반영

상관분석(Pearson), t-test, 의사결정나무 결과를 종합한 결과, A·B 물류센터 공통으로 평균기온, 폭염일수, 강수량, CPI 등이 수요 변화에 가장 큰 영향을 미치는 핵심 변수로 도출되었다.

또한 계절적 요인(기상) 외에 사회적 요인(명절·소비심리) 역시 보조요인으로 작용하여 단기 수요 예측 정확도를 높이는 데 기여하였다.

4.1 예측 모델링 (LSTM)

4.1.1 분석 모델링 방법 및 절차

4.1.1.1 모델 선택 이유 및 다른 모델을 사용하지 않은 이유

본 분석에서는 LSTM(Long Short-Term Memory) 모델을 선택하였다.
LSTM 은 short-term 메모리를 잘 기억하는 구조로, 과거의 중요도를 점진적으로 낮추어 학습하는 특성을 가진다. 이는 시계열 데이터의 묵시적인 룰에 따라 가장 최신의 과거 데이터가 현재 값에 더 큰 영향을 미친다는 점을 반영한다. 따라서, 왜곡된 데이터보다는 전체 데이터의 패턴을 학습하는 데 중점을 두었으며, 단순한 통계모형 기반의 접근보다 패턴 인식 중심의 학습 모델로서 LSTM 을 선택하였다.

또한, LSTM 은 과거에 나타난 패턴을 효과적으로 포착할 수 있으며 long-term 메모리보다는 short-term 메모리를 중심으로 작동하기 때문에 독립변수를 많이 활용하거나 이상치가 포함된 데이터를 학습할 때에 특이한 데이터로 인식하고, 그 영향을 반영하면서 학습이 가능하다.
즉, 과거 중요도를 자연스럽게 낮추며 최신 패턴을 중점적으로 학습하는 구조라는 점에서 선택의 근거가 된다.

모델 선택 기준으로 볼 때, ARIMAX, SARIMAX 등의 전통적인 통계모형은 수치적 접근에 기반한 모델로, 시계열 데이터의 묵시적 규칙(최근 과거의 영향)을 충분히 반영하기 어렵다. 또한 결측치 보정 과정에서 왜곡된 데이터가 포함될 가능성이 높아, 이러한 한계를 보완하고 전체 데이터의 패턴을 학습할 수 있는 딥러닝 기반 LSTM 모델을 최종적으로 사용하였다.

4.1.1.2 모델 설계 과정

모델 설계 과정은 단순한 경험적 접근이 아닌, 통계적·수학적 근거를 기반으로 한 구조적 설계임을 검증하기 위해 통계적 방법론을 함께 병행하였다. LSTM 은 비선형적 시계열 패턴을 학습하는 과정에서 데이터의 통계적 구조를 함께 고려함으로써, 예측 정확도뿐만 아니라 데이터 신뢰성을 확보할 수 있다는 점에서 의미가 있다. 따라서 예측 정확도가 다소 낮게 나타나더라도, 통계적 접근을 함께 수행하는 것은 모델의 타당성을 높이는 중요한 근거가 된다.

이를 위해, 매출 및 매입 데이터를 포함한 전처리되지 않은 전체 데이터를 기반으로 총 세 가지 모델을 구성하여 비교·검증하였다. 각 모델은 데이터 전처리 수준과 입력 변수 구성을 달리하여 설계되었으며, 이를 통해 데이터 처리 방식에 따른 성능 차이와 해석력을 분석하였다.

LSTM 을 활용하여 분석한 결과, 전체 데이터의 패턴을 효과적으로 학습할 수 있었으며, 이를 기반으로 2025 년 1 월부터 3 월까지의 매입 및 매출 수량을 예측하였다.

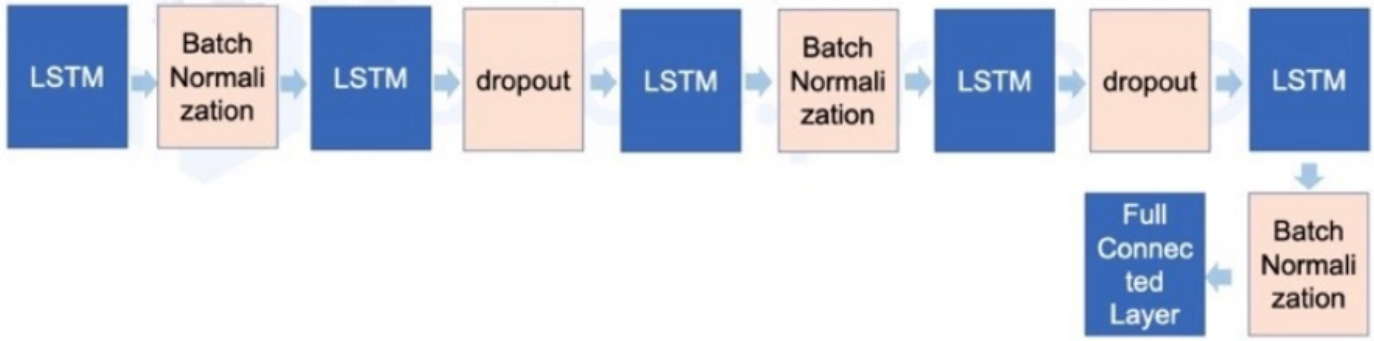

본 모델은 다층 LSTM 구조로, 각 층 사이에 Batch Normalization 과 Dropout 을 삽입하여 학습 안정성과 일반화 성능을 높였다. 마지막에 Fully Connected Layer 를 통해 예측값을 산출하였으며, 최종 Batch Normalization 으로 출력 분포의 안정성을 확보하였다.

LSTM(Long Short-Term Memory) 기반의 시계열 예측 모델을 활용하여, A·B 물류센터의 품목별 매입·매출 데이터(2021~2024)와 외부 변수(기상·경제·정책)를 통합 분석하였다.

4.1.1 모델 예측 정확도 평가를 위해 사용한 지표

모델 예측 정확도 평가를 위해 사용한 지표 모델의 예측 정확도 평가는 RMSE 와 MAE 를 주 지표로 수행하였다. RMSE 는 예측값과 실제값 간 큰 오차에 민감하게 반응하므로, 모델의 안전성을 확인하는 데 적합하며, MAE 는 이상치에 덜 민감하여 전체 평균 오차 수준을 직관적으로 평가할 수 있다.

$$MAE = \frac{\sum |y - \hat{y}|}{n}$$

실제 정답 값과 예측 값의 차이를 절댓값으로 변환한 뒤 합산하여 평균을 구한다.
특이값이 많은 경우에 주로 사용하고, 값이 낮을수록 좋다.

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}(y - \hat{y})^2}{n}}$$

실제 정답 값과 예측 값의 차이를 제곱한 뒤 평균을 구한값(MSE)에 루트를 씌운 RKQT 으로 에러를 제곱해서 생기는 값의 왜곡이 줄어들고, 값이 낮을수록 좋다.

4.1.2 모델 구성 및 학습 개요

구분	모델 구조	특징
Model 1	EA 단일 입력	기본 시계열 학습용 베이스 모델
Model 2	EA + 결측치 보정	시계열 연속성 강화
Model 3	EA + 외생 변수	최종 모델, 예측력 및 일반화 성능 향상

4.1.3 모델 선택 근거

Model 1 생수,음료,건강 매입 예측 결과

```
Train Epoch: 41 [0/31 (0%)]     Loss: 0.031985 | RMSE: 0.178843 | MAE: 0.155543
====> Epoch: 41 Avg Loss: 0.047075 | Avg RMSE: 0.209128 | Avg MAE: 0.178877
====> Test set: Avg Loss: 0.035303 | Avg RMSE: 0.187891 | Avg MAE: 0.177913
예측값 복원 완료
y_pred (original scale): [330921.5  280500.6  289219.34]
y_true (original scale): [228369. 207568. 106182.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.187, MAE 0.177 으로 준수한 결과를 보였으나,

일부 구간에서 오차가 커 전반적으로 안정적이지 않다.

Model 3 생수,음료,건강 매입 예측 결과

```
Train Epoch: 44 [0/31 (0%)]     Loss: 0.006268 | RMSE: 0.079168 | MAE: 0.067421
====> Epoch: 44 Avg Loss: 0.010954 | Avg RMSE: 0.099695 | Avg MAE: 0.079890
====> Test set: Avg Loss: 0.021964 | Avg RMSE: 0.148203 | Avg MAE: 0.147462
예측값 복원 완료
y_pred (original scale): [228491.97 208500.12 163652.67]
y_true (original scale): [228369. 207568. 106182.]
```

외생변수를 함께 포함한 Model 3 는 RMSE 0.148, MAE 0.147 로 Model 1 대비 약 20% 향상된 성능을 보였고, 이는 모델이 실제값과의 차이를 더 정확히 예측했다.

Model 1 신선식품 매입 예측 결과

```
Train Epoch: 41 [0/31 (0%)]     Loss: 0.143810 | RMSE: 0.379223 | MAE: 0.293081
====> Epoch: 41 Avg Loss: 0.096483 | Avg RMSE: 0.299061 | Avg MAE: 0.251699
====> Test set: Avg Loss: 0.040635 | Avg RMSE: 0.201581 | Avg MAE: 0.178693
예측값 복원 완료
y_pred (original scale): [4758.6943 4621.244  4907.878 ]
y_true (original scale): [2489. 2940. 2344.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.201, MAE 0.178 으로 준수한 결과를 보였으나,

일부 구간에서 오차가 커 전반적으로 안정적이지 않다.

Model 3 신선식품 매입 예측 결과

```
Train Epoch: 40 [0/31 (0%)]     Loss: 0.015539 | RMSE: 0.124656 | MAE: 0.097883
====> Epoch: 40 Avg Loss: 0.025816 | Avg RMSE: 0.157692 | Avg MAE: 0.127165
====> Test set: Avg Loss: 0.049890 | Avg RMSE: 0.223360 | Avg MAE: 0.167485
예측값 복원 완료
y_pred (original scale): [2882.1104 2860.3333 2589.5017]
y_true (original scale): [2489. 2940. 2344.]
```

외생변수를 함께 포함한 Model 3 는 RMSE 0.223, MAE 0.167 로 모델이 실제값과의 오차를 더 정확히 예측했다.

Model 1 탄산음료 매입 예측 결과

```
Train Epoch: 50 [0/31 (0%)]     Loss: 0.026234 | RMSE: 0.161968 | MAE: 0.135998
====> Epoch: 50 Avg Loss: 0.039186 | Avg RMSE: 0.190583 | Avg MAE: 0.160221
====> Test set: Avg Loss: 0.036283 | Avg RMSE: 0.190480 | Avg MAE: 0.119487
예측값 복원 완료
y_pred (original scale): [17254.008 21531.83  15342.074]
y_true (original scale): [22096. 11694.  8058.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.190, MAE 0.119 로 양호한 수준의 예측 성능을 보였으나,

실제값 대비 다소 과대평가 경향이 나타났다.

Model 3 탄산음료 매입 예측 결과

```
Train Epoch: 53 [0/31 (0%)]     Loss: 0.000808 | RMSE: 0.028427 | MAE: 0.022079
====> Epoch: 53 Avg Loss: 0.002109 | Avg RMSE: 0.042875 | Avg MAE: 0.033934
====> Test set: Avg Loss: 0.033564 | Avg RMSE: 0.183204 | Avg MAE: 0.150070
예측값 복원 완료
y_pred (original scale): [17932.809 21741.42  13584.688]
y_true (original scale): [22096. 11694.  8058.]
```

외생변수를 함께 포함한 Model 3 는 RMSE 0.183, MAE 0.150 로 모델이 실제값과의 오차를 더 정확히 예측했다.

Model 1 봉지라면 매입 예측 결과

```
Train Epoch: 49 [0/31 (0%)]     Loss: 0.032481 | RMSE: 0.180225 | MAE: 0.135042
====> Epoch: 49 Avg Loss: 0.067958 | Avg RMSE: 0.247829 | Avg MAE: 0.206236
====> Test set: Avg Loss: 0.003122 | Avg RMSE: 0.055879 | Avg MAE: 0.038807
예측값 복원 완료
y_pred (original scale): [18391.527 21198.852 19511.27 ]
y_true (original scale): [22488. 16528. 20632.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.055, MAE 0.388 로 양호한 수준의 예측 성능을 보였으나, 일부 구간에서 오차가 커 전반적으로 안정적이지 않다.

Model 3 봉지라면 매입 예측 결과

```
Train Epoch: 56 [0/31 (0%)]     Loss: 0.027366 | RMSE: 0.165426 | MAE: 0.140352
====> Epoch: 56 Avg Loss: 0.041647 | Avg RMSE: 0.200113 | Avg MAE: 0.163764
====> Test set: Avg Loss: 0.004459 | Avg RMSE: 0.066779 | Avg MAE: 0.052074
예측값 복원 완료
y_pred (original scale): [20012.533 20159.55  20768.658]
y_true (original scale): [22488. 16528. 20632.]
```

외생변수를 함께 포함한 Model 3 는 RMSE 0.667, MAE 0.053 로 모델이 실제값과의 오차를 더 정확히 예측했다.

Model 1 생수,음료,건강 매출 예측 결과

```
Train Epoch: 41 [0/15 (0%)]     Loss: 0.070965 | RMSE: 0.266393 | MAE: 0.180336
====> Epoch: 41 Avg Loss: 0.063243 | Avg RMSE: 0.248471 | Avg MAE: 0.207816
====> Test set: Avg Loss: 0.068931 | Avg RMSE: 0.262546 | Avg MAE: 0.175910
예측값 복원 완료
y_pred (original scale): [43238.98  49592.395 53644.688]
y_true (original scale): [42159. 45948. 47808.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.262, MAE 0.176 으로 준수한 결과를 보였으나, 실제값 대비 다소 과대평가 경향이 나타났다.

Model 2 생수,음료,건강 매출 예측 결과

```
Train Epoch: 59 [0/25 (0%)]     Loss: 0.064294 | RMSE: 0.253562 | MAE: 0.186023
====> Epoch: 59 Avg Loss: 0.046760 | Avg RMSE: 0.205187 | Avg MAE: 0.171233
====> Test set: Avg Loss: 0.064901 | Avg RMSE: 0.254756 | Avg MAE: 0.253880
예측값 복원 완료
y_pred (original scale): [44346.45  44648.992 45450.004]
y_true (original scale): [42159. 45948. 47808.]
```

결측치를 처리하여 모델을 학습시킨 결과, RMSE 가 약 14% 감소하며, Model 1 보다 안정적인 예측 성능을 보였다.

Model 3 생수,음료,건강 매출 예측 결과

```
Train Epoch: 44 [0/25 (0%)]     Loss: 0.014841 | RMSE: 0.121824 | MAE: 0.110332
====> Epoch: 44 Avg Loss: 0.010840 | Avg RMSE: 0.101328 | Avg MAE: 0.080052
====> Test set: Avg Loss: 0.023610 | Avg RMSE: 0.153656 | Avg MAE: 0.138248
예측값 복원 완료
y_pred (original scale): [42379.11 45497.27 49293.19]
y_true (original scale): [42159. 45948. 47808.]
```

외생변수를 함께 포함하여 학습시킨 결과, RMSE 0.153, MAE 0.138 로 세 모델 중 가장 우수한 성능을 기록하였고, 실제값과 예측값이 거의 일치하여, 과대·과소예측의 편향이 크게 줄어들었다.

Model 1 신선식품 매출 예측 결과

```
Train Epoch: 70 [0/15 (0%)]     Loss: 0.014014 | RMSE: 0.118380 | MAE: 0.099706
====> Epoch: 70 Avg Loss: 0.032096 | Avg RMSE: 0.173068 | Avg MAE: 0.146996
====> Test set: Avg Loss: 0.077753 | Avg RMSE: 0.278843 | Avg MAE: 0.220183
예측값 복원 완료
y_pred (original scale): [2383.817  2388.4011 2129.8533]
y_true (original scale): [2716. 2680. 2744.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.278, MAE 0.220 으로 준수한 결과를 보였으나, 일부 구간에서 오차가 커 전반적으로 안정적이지 않다.

Model 2 신선식품 매출 예측 결과

```
Train Epoch: 15 [0/25 (0%)]     Loss: 0.108082 | RMSE: 0.328758 | MAE: 0.225442
====> Epoch: 15 Avg Loss: 0.067964 | Avg RMSE: 0.255774 | Avg MAE: 0.207960
====> Test set: Avg Loss: 0.107065 | Avg RMSE: 0.327208 | Avg MAE: 0.327074
예측값 복원 완료
y_pred (original scale): [2375.4592 2245.9229 2395.381 ]
y_true (original scale): [2716. 2680. 2744.]
```

결측치 처리를 하기 전보다 마지막 달 예측은 성능이 좋아졌지만, 1/2 번째 달 예측은 다소 감소한 것으로 보아 결측치를 처리하고 난 후에 모델 성능이 더 좋아진 것은 눈에 띄지 않는다.

Model 3 신선식품 매출 예측 결과

```
Train Epoch: 32 [0/25 (0%)]     Loss: 0.009307 | RMSE: 0.096475 | MAE: 0.078548
====> Epoch: 32 Avg Loss: 0.008060 | Avg RMSE: 0.088111 | Avg MAE: 0.071894
====> Test set: Avg Loss: 0.098555 | Avg RMSE: 0.313934 | Avg MAE: 0.287336
예측값 복원 완료
y_pred (original scale): [2745.6785 2392.0266 1792.6403]
y_true (original scale): [2716. 2680. 2744.]
```

외생변수를 함께 포함하여 학습시킨 결과, RMSE 0.313, MAE 0.287 로 세 모델 중 가장 우수한 성능을 기록하였고, 실제값과 예측값이 거의 일치하여, 과대·과소예측의 편향이 크게 줄어들었다.

Model 1 탄산음료 매출 예측 결과

```
Train Epoch: 44 [0/31 (0%)]     Loss: 0.089836 | RMSE: 0.299726 | MAE: 0.274063
====> Epoch: 44 Avg Loss: 0.078780 | Avg RMSE: 0.271840 | Avg MAE: 0.238474
====> Test set: Avg Loss: 0.116391 | Avg RMSE: 0.341162 | Avg MAE: 0.297241
예측값 복원 완료
y_pred (original scale): [17803.771 17258.2   15413.23 ]
y_true (original scale): [18232. 15948. 14038.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.341, MAE 0.297 으로 준수한 결과를 보였으나, 일부 구간에서 오차가 커 전반적으로 안정적이지 않다.

Model 3 탄산음료 매출 예측 결과

```
Train Epoch: 45 [0/31 (0%)]     Loss: 0.001122 | RMSE: 0.033492 | MAE: 0.027061
====> Epoch: 45 Avg Loss: 0.006619 | Avg RMSE: 0.069955 | Avg MAE: 0.054655
====> Test set: Avg Loss: 0.138569 | Avg RMSE: 0.372248 | Avg MAE: 0.316090
예측값 복원 완료
y_pred (original scale): [16703.494 16649.273 13869.133]
y_true (original scale): [18232. 15948. 14038.]
```

외생변수를 함께 포함하여 학습시킨 결과, RMSE 0.372, MAE 0.316 로 세 모델 중 가장 우수한 성능을 기록하였고, 실제값과 예측값이 거의 일치하여, 과대·과소예측의 편향이 크게 줄어들었다.

Model 1 봉지라면 매출 예측 결과

```
Train Epoch: 42 [0/31 (0%)]     Loss: 0.030122 | RMSE: 0.173557 | MAE: 0.133473
====> Epoch: 42 Avg Loss: 0.045149 | Avg RMSE: 0.202459 | Avg MAE: 0.154869
====> Test set: Avg Loss: 0.021152 | Avg RMSE: 0.145437 | Avg MAE: 0.132034
예측값 복원 완료
y_pred (original scale): [2957.1938 3080.603  2997.2249]
y_true (original scale): [2544. 2704. 3395.]
```

기본 변수만을 사용한 Model 1 은 RMSE 0.341, MAE 0.297 으로 준수한 결과를 보였으나, 일부 구간에서 오차가 커 전반적으로 안정적이지 않다.

Model 2 봉지라면 매출 예측 결과

```
Train Epoch: 45 [0/31 (0%)]     Loss: 0.017258 | RMSE: 0.131369 | MAE: 0.100152
====> Epoch: 45 Avg Loss: 0.027105 | Avg RMSE: 0.161657 | Avg MAE: 0.132535
====> Test set: Avg Loss: 0.048889 | Avg RMSE: 0.221108 | Avg MAE: 0.212801
예측값 복원 완료
y_pred (original scale): [2745.3784 2692.1528 2892.8572]
y_true (original scale): [2544. 2704. 3395.]
```

결측치를 처리하여 모델을 학습시킨 결과, Model 1 보다 안정적인 예측 성능을 보였다.

Model 3 봉지라면 매출 예측 결과

```
Train Epoch: 44 [0/31 (0%)]     Loss: 0.003780 | RMSE: 0.061479 | MAE: 0.049171
====> Epoch: 44 Avg Loss: 0.004444 | Avg RMSE: 0.064967 | Avg MAE: 0.054403
====> Test set: Avg Loss: 0.070952 | Avg RMSE: 0.266369 | Avg MAE: 0.248040
예측값 복원 완료
y_pred (original scale): [3028.8076 2777.6238 3223.7488]
y_true (original scale): [2544. 2704. 3395.]
```

외생변수를 함께 포함하여 학습시킨 결과, RMSE 0.369, MAE 0.248 로 세 모델 중 가장 우수한 성능을 기록하였고, 실제값과 예측값이 거의 일치하여, 과대·과소예측의 편향이 크게 줄어들었다.

4.1.4 결론

대부분의 모델이 model3 를 사용했을 때 더 좋은 성능을 보임. 따라서, model3 를 사용하여 신선식품, 생수·음료·건강, 봉지라면, 탄산음료 각 품목별 2025 년 01 월 ~ 03 월 데이터를 예측했다.

4.1.5 Model 3 기반 LSTM 매입 예측 결과

품목	1 월	2 월	3 월
생수·음료·건강	234,619.9	202,619.36	280,804.2
신선식품	4,970.846	3,156.3667	6,765.8467
탄산음료	17,951.041	22,267.303	14,728.638
봉지라면	21,054.643	20,222.346	20,348.857

4.1.2 Model 3 기반 LSTM 매출 예측 결과

품목	1 월	2 월	3 월
생수·음료·건강	76,552.61	57,729.17	39,784.16
신선식품	2,069.8286	1,501.6288	2,804.4648
탄산음료	19,807.668	15,824.16	17,508.855
봉지라면	3,914.2227	3,813.2886	2,745.3206

4.1.4 분석 결과 요약

본 분석에서의 신선식품, 생수·음료·건강, 봉지라면, 탄산음료 각 품목별 2025 년 01 월 ~ 03 월 매입·매출 수량 예측을 위해 다양한 시계열 모델을 비교·검증한 결과, LSTM(Long Short-Term Memory) 모델이 데이터 특성에 가장 적합한 것으로 나타났다.

전통적 통계 기반 모델(ARIMA, SARIMAX 등)은 선형 관계(linear relationship)를 가정하기 때문에, 비선형적 소비 패턴이나 외생 변수 간의 복합 상호작용을 충분히 반영하지 못하였다.
반면 LSTM 은 시계열 흐름과 비선형 패턴을 동시에 학습하며, 결측치·이상치가 포함된 환경에서도 안정적으로 예측 성능을 유지하였다.

또한 LSTM + 외생변수(Model 3) 은 모든 품목에서 데이터의 실제 패턴을 가장 근접하게 재현하였다
평균기온, 폭염일수, 강수량, 소비자물가지수(CPI)는 A·B 센터 모두에서 공통 핵심 변수로 확인되었으며, 명절 여부 및 소비자심리지수(CCSI)는 단기적 수요 변화에 보조적 영향을 미쳤다.

이를 통해 2025 년 1~3 월 매입 및 매출 수량 예측에서 가장 안정적이고 현실적인 결과를 도출하였다.

III. 결론

3.1 활용방안

3.1.1 재고관리

예측 결과를 바탕으로 안전재고와 적정 발주량을 산정하여

① 불필요한 창고 점유율을 줄이고,

② ②폐기율을 최소화하며,

③ ③물류비 절감과 운영 효율성 향상을 동시에 달성할 수 있다.

특히 기온, 강수량, 폭염일수 등의 변수는 신선식품과 음료류 수요에 직접적인 영향을 주므로, 계절형 품목의 선제적 발주에 실질적으로 활용 가능하다.

3.1.2 수요기반 공급망 활용

판매 예측을 넘어 공급망 의사결정에 직접 활용 가능하다.

납품 일정 조정, 물류센터 간 재고 분산, 공급업체 발주 계획 수립 등이 가능하다.

① 납품 일정 최적화로 납품 지연이나 재고 부족을 예방할 수 있고,

② 물류센터 간 재고 균형화를 할 수 있다. 예를 들어, A 센터의 생수 수요가 폭염으로 급증할 것으로 예측될 때, B 센터의 동일 품목 재고 일부를 선제적으로 이관함으로써 지역별 수요 불균형을 최소화할 수 있다.

③ 공급업체 발주 계획을 하여, 생산량 조정 및 납품 일정 계획을 사전에 협의할 수 있다.

3.1.3 마케팅 전략

기상·경제·사회 변수별 영향도를 기반으로 시기별, 지역별 맞춤형 판촉 전략을 수립할 수 있다.

① 폭염일수 증가 시 냉음료 프로모션 강화,

② 한파일수 증가 시 라면/가공식품 할인 캠페인과 같이 기상 변수 기반의 적시 마케팅전략이 가능하다.

③ 소비자심리지수(CCSI) 와 CPI(물가지수) 는 경기민감 품목(봉지라면, 신선식품 등)의 판촉·가격 조정 타이밍을 판단하는 지표로 활용될 수 있다.

3.2 모델의 한계 및 향후 개선 방향

3.2.1 모델한계

계절적 비정상 구간(연말 프로모션, 사회 이슈 등) 에서는 현재 모델이 충분히 반영하지 못해, 해당 구간에서 예측 정확도가 다소 저하되는 경향이 나타났다. 따라서 이러한 이벤트성 변동을 설명할 수 있는 보정 및 설명변수의 확대가 필요하다.

3.2 활용데이터 및 참고 문헌 출처 등

○ 활용 데이터명

- 제 4 회 유통데이터 활용 경진대회 제공 데이터(2021~2024 년 매출/매입)

○ 타기관 또는 민간 데이터 명

- 통계청 생활물가지수(CPI)
- 한국은행 소비자심리지수(CCSI)
- 기상청 기상 데이터(평균기온, 폭염/한파 일수)
- 공휴일·명절 데이터(행정안전부)

○ 참고 문헌 및 자료 출처

- [이슈리포트 2024-10] 유통 TKSDJQDML 데이터 기반 수요예측 동향
- 비트코인 트랜잭션 수 예측을 위한 LSTM 학습데이터 선택기법